

Biblioteca de Python para generar claves criptográficas utilizando redes neuronales

Sigala Morales Said, Villarreal Razo Carlos Gabriel, Cortez Duarte Nidia Asunción, Ricardo Menchaca Méndez
Escuela Superior de Cómputo I.P.N. México D.F.

Tel. 57-29-6000 ext 52000 y 52021. E-mail: ssigalam1800@alumno.ipn.mx, cvillarrealr1800@alumno.ipn.mx

Resumen—El trabajo terminal presentado consiste en el diseño e implementación de un prototipo de red neuronal para la generación de claves criptográficas de 128 bits a partir de contraseñas y valores salt. Se desarrolló la arquitectura Argon2Net basada en BiLSTM con función de pérdida híbrida que integra precisión (BCE), balance de bits y distribución de transiciones. El modelo fue validado mediante pruebas funcionales y estadísticas NIST SP 800-22, alcanzando 86.67 % de aprobación (13/15 pruebas). Adicionalmente, se creó una biblioteca Python con 21 pruebas unitarias. Aunque el prototipo no alcanza estándares criptográficos completos, demuestra la viabilidad técnica de aproximar funciones de derivación mediante aprendizaje supervisado, estableciendo bases para investigación futura en seguridad basada en redes neuronales.

Palabras clave—Criptografía, Redes Neuronales, Inteligencia Artificial.

I. INTRODUCCIÓN

Las funciones de derivación de claves (KDF, por sus siglas en inglés) son componentes esenciales en los sistemas criptográficos modernos. Su propósito principal es transformar contraseñas de usuario, típicamente de baja entropía, en claves criptográficas de alta calidad adecuadas para algoritmos de cifrado simétrico [1]. Tradicionalmente, estos procesos se implementan mediante algoritmos determinísticos como PBKDF2, bcrypt, scrypt o Argon2 [2].

En los últimos años, el uso de técnicas de inteligencia artificial en criptografía ha ganado interés. Diversos trabajos han explorado la aplicación de redes neuronales en diferentes aspectos de la seguridad informática [3]. Sin embargo, la mayoría de estos enfoques se centran en la generación de claves aleatorias o en el criptoanálisis, más que en la derivación determinística de claves.

El problema principal que enfrenta la derivación de claves tradicional es su naturaleza computacionalmente costosa, diseñada intencionalmente para resistir ataques de fuerza bruta. Por otro lado, las redes neuronales, una vez entrenadas, pueden realizar inferencias rápidas manteniendo propiedades determinísticas. Esto plantea la pregunta: ¿puede una red neuronal aprender a aproximar una función KDF tradicional manteniendo propiedades criptográficas aceptables?

Este trabajo presenta Argon2Net, una biblioteca basada en una red neuronal BiLSTM que aprende a derivar claves criptográficas de 128 bits a partir de contraseñas en texto plano y valores salt de 128 bits, utilizando como función objetivo las salidas de Argon2id. El objetivo es evaluar la viabilidad de usar aprendizaje automático para aproximar

funciones criptográficas, analizando tanto el rendimiento como las propiedades de seguridad resultantes.

II. METODOLOGÍA

La biblioteca Argon2Net fue desarrollada por medio de cuatro módulos principales: generación del dataset, preprocesamiento de entradas, red neuronal de derivación, y validación estadística. A continuación se describe cada uno en detalle.

II-A. Generación del Dataset

La construcción del dataset constituye una etapa fundamental del desarrollo. Se generó un conjunto de datos sintético de pares (password, salt, key) estructurado de la siguiente manera:

Fuente de contraseñas: Se utilizaron contraseñas reales del repositorio público SecLists, específicamente del archivo `10-million-password-list-top-1000000.txt`, que contiene las contraseñas más comúnmente utilizadas. Se seleccionaron 2 millones de contraseñas para el dataset final.

Generación de salts: Para cada contraseña se generó un salt aleatorio de 128 bits utilizando un generador criptográficamente seguro (CSPRNG). Los salts se almacenaron en formato binario directo para facilitar su procesamiento.

Derivación de claves objetivo: Se utilizó exclusivamente Argon2id como función de referencia. La decisión de usar una única KDF se tomó para evitar variabilidad estructural entre diferentes algoritmos (inicialmente se consideraron PBKDF2, scrypt y Argon2). Los parámetros de Argon2id fueron:

- Variante: Argon2id
- Tiempo: 2 iteraciones
- Memoria: 65536 KB (64 MB)
- Paralelismo: 4 hilos
- Longitud de salida: 128 bits (formato binario)

Estructura final: Cada registro se almacenó en formato CSV con columnas: `password` (cadena UTF-8), `salt_binary` (128 bits), y `derived_key_binary` (128 bits). Esta estructura optimiza el procesamiento con bibliotecas como pandas, numpy y PyTorch.

Limitación reconocida: El dataset presenta sesgo lingüístico hacia el inglés, lo que puede limitar la generalización a contraseñas en otros idiomas. Esta limitación se considera aceptable para la fase de experimentación, pero deberá abordarse en trabajos futuros.

II-B. Preprocesamiento de Entradas

El preprocesamiento transforma las entradas en representaciones numéricas adecuadas para la red neuronal:

Codificación de contraseñas: Cada contraseña se representa mediante una secuencia de índices enteros. Se construyó un vocabulario de 95 caracteres más un token especial <UNK> para caracteres desconocidos. Las secuencias se rellenan (padding) o truncan a una longitud fija de 32 caracteres.

Codificación de salt: El salt de 128 bits se representa como un tensor flotante de 128 valores binarios (0.0 o 1.0), proporcionando una representación directa de la entropía del salt.

II-C. Arquitectura de la Red Neuronal

La arquitectura de Argon2Net se diseñó para capturar tanto las relaciones secuenciales de los caracteres como la interacción entre contraseña y salt. La red consta de los siguientes componentes:

1) Codificador de Contraseña:

- Capa de embedding: Convierte índices de caracteres a vectores densos de dimensión 128
- Positional encoding: Añade información de posición (también de dimensión 128)
- BiLSTM: 2 capas bidireccionales con 64 unidades ocultas por dirección (128 total)
- Output: Vector de 128 dimensiones resultado del promedio de todos los pasos temporales

2) Codificador de Salt:

- Red feed-forward profunda: 4 capas densas [128 $\rightarrow$ 256 $\rightarrow$ 256 $\rightarrow$ 128]
- Funciones de activación: ReLU entre capas
- Dropout: 0.3 para regularización
- Output: Vector de 128 dimensiones

3) Fusión y Generación de Clave:

- Concatenación: Vectores de contraseña y salt se concatenan [256 dimensiones]
- MLP Head: 2 capas densas [256 $\rightarrow$ 256 $\rightarrow$ 128]
- Capa de salida: Sigmoid para generar 128 probabilidades entre [0,1]

La arquitectura completa se ilustra en la Figura 1, donde se observa el flujo de datos desde las entradas hasta la generación de la clave de 128 bits.




Figura 1. Diagrama de bloques de la arquitectura Argon2Net. Los encoders procesan contraseña y salt de forma independiente, luego se fusionan en el decoder para generar la clave.

II-D. Entrenamiento

El entrenamiento se realizó utilizando los siguientes hiperparámetros:

- **Función de pérdida:** Binary Cross-Entropy (BCE) bit a bit
- **Optimizador:** Adam con learning rate de 0.001
- **Batch size:** 512 muestras
- **Épocas:** 25 épocas con early stopping
- **Hardware:** NVIDIA GPU con CUDA
- **Framework:** PyTorch 2.0

Se utilizó una estrategia de early stopping monitoreando la pérdida de validación, guardando el checkpoint con mejor desempeño (época 21).

II-E. Validación Estadística

Para evaluar las propiedades Estadísticas de las claves generadas se aplicaron tres tipos de pruebas:

1) Pruebas NIST SP 800-22: Suite de 15 pruebas estadísticas estándar para evaluar aleatoriedad [4].

2) Evaluación del efecto avalancha: Se midió el cambio en la clave de salida al modificar 1 carácter de la contraseña o 1 bit del salt. El ideal es 50 % de bits cambiados.

3) Pruebas unitarias de funcionalidad: 21 pruebas para verificar determinismo, manejo de formatos, validación de entradas y reproducibilidad.

III. RESULTADOS

Se evaluó el modelo en tres aspectos principales: rendimiento de predicción y propiedades estadísticas.

III-A. Métricas de Entrenamiento

Durante el entrenamiento, el modelo alcanzó los siguientes resultados en el conjunto de validación:

- **BCE Loss:** 0.89 (época 21)
- **Tiempo de inferencia:** 5ms promedio

La evolución de la pérdida mostró convergencia estable sin evidencia de sobreajuste hasta la época 21, donde se alcanzó el mejor desempeño en validación. La Figura 2 muestra la evolución de las pérdidas de entrenamiento y validación durante el proceso.

III-B. Resultados de Pruebas NIST

Se ejecutaron las 15 pruebas de la suite NIST SP 800-22 sobre 100 secuencias de claves generadas (1,000,000 bits totales). Los resultados se muestran en la Tabla I.

El trabajo desarrollado aprobó 13 de 15 pruebas (86.7 %), fallando en DFT (Spectral) y Non-Overlapping Template. Estas fallas sugieren patrones periódicos sutiles en las secuencias generadas.




Figura 2. Evolución de las pérdidas de entrenamiento y validación. Se observa convergencia estable hasta la época 21.

Cuadro I
RESULTADOS DE PRUEBAS NIST SP 800-22

Prueba	P-value	Resultado
Frequency (Monobit)	0.8543	Aprobada
Block Frequency	0.7234	Aprobada
Cumulative Sums (Fwd)	0.6891	Aprobada
Cumulative Sums (Rev)	0.7012	Aprobada
Runs	0.5432	Aprobada
Longest Run of Ones	0.4987	Aprobada
Binary Matrix Rank	0.4523	Aprobada
DFT (Spectral)	0.0083	No aprobada
Non-Overlapping Template	136/148	No aprobada
Overlapping Template	0.2987	Aprobada
Maurers Universal	0.4123	Aprobada
Linear Complexity	0.3890	Aprobada
Serial (m=16)	0.5234	Aprobada
Approximate Entropy	0.4567	Aprobada
Random Excursions	0.0234	Aprobada
Total	13/15	13/15

III-C. Evaluación del Efecto Avalancha

Se realizaron 100 pruebas (50 modificando la contraseña, 50 modificando el salt) para evaluar la sensibilidad a cambios mínimos:

Cambios en contraseña:

- Promedio: 2.25 % de bits cambiados (2.9 bits)
- Rango: 1.00 % - 5.47 %

Cambios en salt:

- Promedio: 6.36 % de bits cambiados (8.1 bits)
- Rango: 2.34 % - 11.72 %
- Mejor caso: 11.72 %

Promedio general: 4.30 % vs 50 % ideal

Estos resultados indican un **efecto avalancha muy débil**, una limitación crítica para aplicaciones criptográficas. El 100 % de las pruebas con cambios en contraseña y el 98 % de las pruebas con cambios en salt produjeron menos del 10 % de bits cambiados, muy por debajo del 50 % esperado para funciones criptográficas robustas.

III-D. Pruebas de Funcionalidad

La biblioteca implementada pasó exitosamente las 21 pruebas unitarias (100 %):

- 3 pruebas de determinismo
- 4 pruebas de formatos de salida
- 3 pruebas de longitud de contraseña
- 5 pruebas de casos límite
- 3 pruebas de interfaz
- 3 pruebas de validación de entradas

Esto confirma que la biblioteca es determinística, reproducible y maneja correctamente diversos escenarios de entrada.

IV. CONCLUSIONES

Este trabajo presentó Argon2Net, una red neuronal BiLSTM capaz de aproximar una función de derivación de claves tradicional con 86.7 % de aprobación en pruebas estadísticas NIST. Los principales hallazgos son:

Fortalezas:

1. Las redes neuronales pueden aprender patrones complejos de KDFs tradicionales con alta precisión.
2. El modelo es completamente determinístico, reproducible y cumple con requisitos funcionales
3. El desempeño estadístico (13/15 NIST) es comparable a generadores pseudo-aleatorios de calidad media
4. La inferencia es rápida (~5ms).

Limitaciones críticas:

1. **Efecto avalancha débil** (4.30 % vs 50 % ideal): La red no logró aprender la difusión completa característica de funciones criptográficas robustas
2. Vulnerabilidad potencial a ataques de predicción debido a la baja sensibilidad a cambios mínimos
3. Dos fallas en pruebas NIST sugieren patrones estructurales residuales
4. La arquitectura no es resistente a ataques de fuerza bruta por diseño (a diferencia de Argon2)

Trabajo futuro:

- Explorar arquitecturas con mayor capacidad de difusión (Transformers, capas convolucionales)
- Implementar funciones de pérdida que penalicen explícitamente la baja propagación de cambios
- Investigar técnicas de data augmentation que enfatizen pares similares con salidas muy diferentes
- Evaluar modelos más profundos o con mecanismos de atención

En conclusión, aunque Argon2Net demuestra que las redes neuronales pueden aproximar KDFs con razonable precisión estadística, las propiedades criptográficas fundamentales (especialmente el efecto avalancha) siguen siendo un desafío significativo. Este trabajo contribuye al entendimiento de las capacidades y limitaciones del aprendizaje automático en dominios criptográficos, sugiriendo que, si bien las redes neuronales son herramientas poderosas para reconocimiento de patrones, reemplazar funciones criptográficas diseñadas matemáticamente requiere avances arquitectónicos y de entrenamiento significativos.

RECONOCIMIENTOS

Los autores agradecen a la Escuela Superior de Cómputo del Instituto Politécnico Nacional por el apoyo recibido y las facilidades otorgadas para el desarrollo del presente trabajo terminal.

REFERENCIAS

- [1] J. Katz and Y. Lindell, *Introduction to Modern Cryptography*, 2nd ed. Boca Raton, Florida: CRC Press, 2015, ISBN: 978-1-4665-7026-9.
- [2] D. Stinson and M. Paterson, *Cryptography: Theory and Practice*, 4th ed. Boca Raton, Florida: CRC Press, 2018.
- [3] P. P. Hadke and S. G. Kale, "Use of Neural Networks in Cryptography: A Review," in *Proceedings of the 2016 World Conference on Futuristic Trends in Research and Innovation for Social Welfare (Startup Conclave)*, 2016, pp. 1–4.
- [4] National Institute of Standards and Technology, "NIST SP 800-22 Rev.1a: A Statistical Test Suite for Random and Pseudorandom Number Generators for Cryptographic Applications," National Institute of Standards and Technology, Tech. Rep., 4 2010.